Final Project Data Science Academy (DSA)
COMPFEST 18

Identity Card Optical Character Recognition (OCR)



Sumber

Deskripsi Masalah

Know Your Customer (KYC) merupakan proses verifikasi identitas pelanggan yang wajib dilakukan oleh lembaga keuangan, perbankan, dan berbagai industri yang diatur oleh regulasi anti pencucian uang (AML). Proses ini umumnya melibatkan pengumpulan dan verifikasi dokumen identitas seperti KTP, paspor, SIM, dan dokumen pendukung lainnya yang sebagian besar tersedia dalam bentuk gambar hasil foto atau scan.

Tantangan utama dalam otomasi proses KYC terletak pada ekstraksi informasi terstruktur dari dokumen identitas yang memiliki variasi tinggi — mulai dari **perbedaan format** antar negara, **kualitas gambar** yang tidak konsisten, **kondisi pencahayaan**, hingga dokumen yang lusuh atau terlipat. Kesalahan dalam ekstraksi data identitas dapat berdampak serius, mulai dari penolakan pelanggan yang sah hingga lolosnya pelaku penipuan identitas.

Dalam tantangan ini, peserta diminta untuk membangun pipeline **OCR** yang mampu mengekstrak informasi kunci dari dokumen identitas secara akurat seperti nama, tanggal lahir, alamat, dan lain-lain. Peserta diberikan **kebebasan** dalam menentukan pendekatan yang digunakan, baik berbasis model deep learning dari awal, fine-tuning model yang sudah ada, maupun kombinasi teknik preprocessing dan post-processing untuk meningkatkan akurasi ekstraksi.

Selain membangun pipeline utama, peserta juga dapat mengeksplorasi pendekatan lanjutan seperti deteksi dan segmentasi field dokumen, validasi format data hasil ekstraksi, penanganan berbagai jenis dokumen identitas, atau deteksi dokumen palsu berdasarkan anomali visual. Paparkan secara jelas metodologi yang digunakan, evaluasi performa yang terukur, serta bagaimana solusi yang dikembangkan dapat mempercepat dan mengamankan proses verifikasi identitas di dunia nyata.

Dataset

Dataset beserta detail terkait dapat diakses melalui link berikut:
FINAL PROJECT DSA

Submisi Berkas:

1. **Paparan Lengkap**: Slides (.pdf)
2. **Code**: Python Notebook (.ipynb)
3. **File/link Dashboard Live**: Tableau/Google Data Studio

Instruksi & Proses Analisis

Seluruh proses mencakup **minimal** langkah-langkah berikut (tidak harus terurut, format apapun dibebaskan):

1. **Business Understanding & Problem Statement**
2. **Data Understanding & EDA**
3. **Data Preprocessing & Feature Engineering**
4. **Modelling & Optimization**
5. **Model Evaluation**
6. **Business Recommendations & Insights**

Notes & Rules

1. Peserta **wajib** menggunakan keseluruhan dataset yang telah disediakan tanpa terkecuali.
2. Peserta **tidak diperbolehkan** menambahkan dataset eksternal sebagai data pendukung.
3. Peserta **bebas** menentukan apakah akan melakukan training model sendiri atau langsung menggunakan model yang sudah ada (inference only).
4. Peserta **bebas** menggunakan model pretrained maupun membangun model dari awal (from scratch), atau kombinasi keduanya.
5. Peserta **bebas** menentukan metrik evaluasi yang digunakan, selama metrik tersebut relevan dan dapat merepresentasikan performa OCR secara objektif dan terukur.
6. Peserta **tidak diperbolehkan** menggunakan model berbasis Large Language Model (LLM) atau Vision-Language Model (VLM) sebagai komponen pipeline OCR.
7. Peserta **tidak diperbolehkan** menganotasi gambar secara manual.

8. Peserta tidak boleh menggunakan teknik automasi seperti AutoML platforms (H2O.ai, Google AutoML, dll.) maupun Automated Feature Engineering tools (Featuretools, tsfresh, dll.).
9. Peserta boleh menggunakan library atau tools apapun selain yang tidak diperbolehkan di atas, termasuk library OCR konvensional seperti Tesseract, EasyOCR, PaddleOCR, dan sejenisnya.
10. Dataset yang disediakan dilengkapi dengan file **ground_truth.csv** yang memuat kolom berikut: filename, name, birth_date, address. File ini digunakan sebagai acuan evaluasi hasil ekstraksi yang dihasilkan oleh pipeline peserta.

Rubrik Penilaian

Kategori Utama	Sub-Komponen Penilaian	Bobot Komponen
A. Metode & Teknis Proyek	1. Business Understanding & Problem Statement	5%
	2. Data Understanding & Exploratory Data Analysis (EDA)	5%
	3. Data Preprocessing & Feature Engineering	15%
	4. Modelling & Optimization	15%
	5. Model Evaluation & Technical Interpretation	5%
	6. Business Recommendations & Insights	10%
	7. Code Quality, Structure & Cleanliness	5%
B. Sesi Presentasi	1. Presentation Structure & Visual Design	10%
	2. Communication Skills & Delivery	15%
	3. Q&A Mastery & Domain Understanding	15%
TOTAL		**100%**